

Notes de cours – Semaine 2

Tableaux de fréquences**2.1 Données brutes**

Lors d'une étude statistique sur une population quelconque, nous avons vu qu'il faut tout d'abord déterminer la population visée, l'échantillon choisi dans le cas d'un sondage ainsi que les variables. Lorsque la collecte de données est complétée, il faut organiser toute l'information recueillie de sorte à ce qu'on puisse en analyser les données et présenter les résultats aux publics.

Cette partie, que nous appelons la présentation de données, est où nous pourrions commencer à appliquer pratiquement nos notions théoriques sur Excel. Notez bien que chaque action ou tâche particulière qui sera nécessaire pour faire les labos et les examens seront expliquées en détails avec support visuels dans les vidéos tutorielles faites par Francis Beauchemin, cher collègue du département des mathématiques. Nous verrons aussi comment faire en classe. Ces vidéos serviront donc de références futures lors de votre étude à la maison et lorsque vous ferez vos laboratoires.

Données brutes	Données des variables à l'étude, récoltées de la population ou de l'échantillon. Elles sont entrées dans un logiciel et codées si nécessaire.
-----------------------	---

Nous utiliserons l'exemple suivant :

En 2023, un chercheur s'est intéressé à la différence dans la performance scolaire au cégep entre les étudiant(e)s droitier(e)s et gaucher(e)s. Il réalisa son étude au cégep du Vieux Montréal où il interrogea 40 étudiant(e)s ayant complété exactement 3 sessions.

Il recueillit des données à propos de l'âge, le niveau de motivation face aux études (sur une échelle de 0, complètement démotivé(e) à 5, extrêmement motivé(e)), si le choix de carrière est clair (oui ou non), la main principale avec laquelle ils et elles écrivent, le nombre d'heures d'étude moyen par semaine, la moyenne générale, le nombre de cours échoués au collégial et le temps requis pour recopier un texte de 150 mots.

Exemple 2.1. En vous référant à l'exemple ci-dessus, répondez aux questions suivantes.

- Est-ce un recensement ou un sondage ?
- Quelle est la population visée par l'étude ?
- Quel est l'échantillon ?

- d) Quelle est la taille de l'échantillon ?
- e) Quelle est la nature de chacune des variables à l'étude ?
- A = Âge
 - M = Niveau de motivation
 - C = Certitude du choix de carrière
 - P = Main principale d'écriture
 - E = Nombre d'heures d'étude moyen hebdomadaire
 - G = Moyenne générale (*arrondie sur Omnivox)
 - X = Nombre d'échecs
 - T = Temps requis pour recopier un texte de 150 mots

Les données brutes récoltées lors de cette étude sont dans le document Excel *Données – Exemple notes de cours* sur Léa.

	A	B	C	D	E	F	G	H	I
1	Individu	Âge	Motiv	Choix	Main	Étude	Moy.générale	Échecs	Temps
2	1	18	4	1	G	2	70	1	7,54
3	2	17	1	2	D	15	81	0	6,91
4	3	17	2	2	D	7	66	2	6,89
5	4	18	5	1	D	10	62	3	7,81
6	5	19	0	2	G	9	62	0	6,2
7	6	20	3	1	D	2	60	2	8,2
8	7	22	3	2	D	3	65	0	7,12
9	8	25	4	1	D	22	93	0	6,1
10	9	18	4	1	D	12	84	0	6,35
11	10	19	4	1	D	14	86	0	7,25
12	11	19	4	2	D	0	57	6	9,4

On affichera toujours le nom des variables sur la première ligne du tableau, ou du moins, une abréviation claire. La première colonne sert à identifier les individus par un nombre tout en gardant la confidentialité de ceux-ci.

Pour les modalités d'une variable qualitative, il est possible d'écrire des mots ou des lettres, comme pour la variable de la main principale (G ou D), ou un code numérique, comme pour la variable de la certitude du choix de carrière (1 - oui ou 2 - non).

2.2 Tableau de fréquences

Après la récolte des données brutes vient la présentation des données. Nous commençons par le tableau de fréquence. Il suivra toujours le même modèle de base ci-dessous, excepté la colonne des fréquences cumulées qui ne sera pas présente pour les variables qualitatives nominales.

Répartition de [*n unités statistiques*] selon [*nom de la variable*], [*lieu*], [*année de réalisation*].

[<i>nom de la variable</i>]	Nombre de [<i>unités statistiques</i>]	Pourcentage de [<i>unités statistiques</i>]	Pourcentage cumulé de [<i>unités statistiques</i>]
Modalité/Valeur/Classe 1			
Modalité/Valeur/Classe 2			
Modalité/Valeur/Classe 3			
...			
Total	<i>n</i> ou <i>N</i>	100,0	

Source : [*lien ou information de la source*]

On remarque que... [*courte interprétation du tableau.*]

Titre : Le titre doit être centré et ne pas dépasser la largeur du tableau. Si le lieu et la date ne sont pas connus, nous ne les indiquons pas. Pour un recensement, la taille *N* n'a pas besoin d'être précisée.

Modalité/Valeur/Classe : Elles doivent être en ordre croissant, exceptées les modalités de variables qualitatives nominales où l'ordre n'importe pas.

Pourcentage : Les pourcentages doivent avoir une décimale de précision. La dernière ligne sera toujours 100,0. Puisque nous devons parfois arrondir les valeurs, il se peut que le total des valeurs arrondies soit 99,9 ou 100,1, on écrit tout de même 100,0.

Pourcentage cumulé : Les pourcentages cumulés doivent avoir une décimale de précision. La dernière ligne est vide, puisque nous atteignons le 100,0% à la dernière modalité/valeur/classe. Dans le cas d'une variable qualitative nominale, cette colonne n'existe pas.

Source : Écrire « Source inconnue » si on ne la connaît pas.

Exemple 2.2. Quels sont les coquilles dans les tableaux suivants ?

a)

Répartition de 500 québécois ayant vu le film Avengers , en avril 2018, selon leur personnage préféré.

Personnage préféré	Effectifs	Pourcentage des effectifs
Iron Man	99	19,8
Capitaine América	192	38,4
Panthère Noire	48	9,6
Hulk	26	5,2
Thor	135	27
Total général	500	100

b)

Main directrice	Nombre d'étudiant.e.s	Pourcentage d'étudiant.e.s (%)
Gauche	6	15,0
Droite	34	85,0
Total	40	100,0

Source : Étude menée au cégep du Vieux Montréal

On remarque qu'il y a des gauchers et des droitiers.

Exemple 2.3. Imaginons que nous faisons une étude sur les étudiants en informatique au cégep du Vieux Montréal. Nous nous intéressons aux nombres de langues parlées. Complétez le tableau de fréquences suivant en récoltant les données de votre classe comme échantillon.

a) Remplir le tableau de fréquence suivant :

Source :

On remarque que ...

b) Que pouvons nous dire sur la valeur ?

c) Que pouvons nous dire sur la valeur ?

Fini les calculs à la main ! Nous utiliserons Excel pour créer nos tableaux plus efficacement. Les capsules vidéo avec les explications détaillées pour chaque partie sont dans l'énoncé du *Labo 1* sur Léa.

Exemple 2.4. Créez un tableau de fréquences pour les variables **Niveau de motivation** et **Main principale** des données brutes se trouvant dans le document *Données – Exemples notes de cours*.

2.3 Classes pour variables quantitatives

Lorsque nous avons énormément de valeurs possibles pour une variable quantitative discrète, ou encore, lorsque nous avons une variable continue, nous réalisons que faire un tableau avec une ligne pour chaque valeur différente serait une horreur visuelle ! Pour présenter ce genre de données en tableau, nous séparons les valeurs en classe.

Étendu	L'étendu des données est la différence entre la plus grande et la plus petite valeur des données brutes. $E =$
Amplitude	L'amplitude est la largeur des classes. Chaque classe a la même largeur pour que le tout reste uniforme.

Chaque cas est différent, donc on doit choisir manuellement le nombre de classe voulu ainsi que le début de chaque classe.

Étapes pour créer les classes :

1. Calculer l'étendu E .
2. Choisir le nombre k de classes « voulu » selon le nombre de données totales (cela peut changer légèrement plus tard) à l'aide du tableau suivant :

Nombre de données	Nombre de classes k
0 à 9	0
10 à 19	5
20 à 39	6
40 à 79	7
80 à 159	8
160 à 319	9
320 à 639	10
640 à 1279	11
1280 à 2559	12
2560 à 5119	13
5120 à 10 239	14
10 240 et plus	15

Source : Amyotte, L. & Pépin, J.-N. (2017). Méthodes quantitatives : applications à la recherche en sciences humaines. 4e éd. ERPI sciences humaines. (p. 93)

3. Calculer l'amplitude théorique (on ajustera manuellement l'amplitude).

$$A_T =$$

4. Choisir l'amplitude la plus pratique qui rendrait la lecture du tableau facile et efficace. Par exemple : 2, multiples de 5, de 10, de 100, etc. dépendant du contexte. Utiliser la même précision que les données brutes.
5. Choisir la borne inférieure de la première classe. Il faut que la première classe contienne au moins 1 valeur. Il faut utiliser le « gros bon sens ».
6. Notations possibles pour les classes : $[5, 10[$ 5 à 10 5 – 10
Par convention, la borne inférieure est incluse et la borne supérieure est exclue.

Nous utiliserons, bien sûr, Excel pour trier les données dans un tableau à classe lorsqu'il y aura trop de valeurs possibles. En revanche, l'amplitude des classes ainsi que le début de la première classe doivent être trouvés manuellement ! Il est important de suivre les étapes précédentes.

Exemple 2.5. Créez un tableau de fréquences pour les variables **Moyenne générale** et **Temps requis pour recopier un texte de 150 mots** des données brutes se trouvant dans le document *Données – Exemple notes de cours*.