

DOSSIER CLIENT

Boréal Services inc.

Infrastructure locale pour un agent conversationnel d'IA générative

	Objet du dossier Ce document présente le contexte, les besoins et les contraintes communiqués par Boréal Services inc. pour l'acquisition d'un système informatique destiné à héberger localement son futur agent conversationnel.
--	--

En bref

Organisation	PME québécoise d'environ 70 personnes
Utilisation	Agent conversationnel pour le service à la clientèle, avec accès public et usage interne
Hébergement	Infrastructure contrôlée par Boréal et située au Québec
Horizon visé	Environ 5 ans, avec possibilité d'évolution du système
Budget prévu	8 000 \$ CA avant taxes pour l'acquisition initiale

Le besoin en une phrase

Boréal souhaite acquérir un système informatique capable d'exécuter localement son agent conversationnel dès maintenant, tout en conservant une marge raisonnable pour l'entretien, le remplacement de composants et l'évolution future de la charge de travail.

	Document commun aux deux projets certificatifs Le même contexte client sert à la recherche technique sur la mémoire et à la recommandation de configuration. Les consignes propres à chaque remise seront fournies séparément.
--	--

1. L'entreprise

Boréal Services inc. est une PME québécoise qui fournit des services administratifs et techniques à des organisations privées et publiques. Elle emploie environ 70 personnes et détient plusieurs contrats avec des organismes du secteur public québécois.

Son équipe de service à la clientèle répond quotidiennement à des questions récurrentes portant sur les comptes, les services, la documentation et les demandes de soutien. Boréal souhaite automatiser une partie de ces échanges tout en maintenant l'intervention humaine lorsque la demande le nécessite.

2. Le projet

Boréal prévoit déployer un agent conversationnel fondé sur un modèle de langage de grande taille (LLM). L'application sera développée et maintenue par un fournisseur logiciel externe. Le fournisseur a déjà testé la charge de travail prévue et a communiqué à Boréal les exigences techniques minimales présentées dans ce dossier.

Portée technique

Le fournisseur logiciel demeure responsable du choix, de la configuration et du fonctionnement du modèle. Boréal cherche ici à choisir l'infrastructure informatique qui hébergera ce service.

3. Hébergement et maîtrise des données

Dans le cadre de sa stratégie de protection des renseignements personnels, de gestion des risques et de conformité, Boréal a décidé que les conversations des clients et les documents internes utilisés par l'agent conversationnel seront traités sur une infrastructure qu'elle contrôle au Québec.

- Les requêtes des clients et les documents internes destinés au chatbot ne doivent pas être transmis à un service public d'IA générative pour l'inférence courante.
- Le système sera installé dans une salle d'équipement sécurisée de Boréal au Québec.
- L'accès à Internet demeure permis pour l'administration, la documentation, les mises à jour et les autres activités normales qui n'envoient pas le contenu confidentiel du chatbot à un service d'IA public.

4. Profil d'utilisation

Utilisateurs internes	Environ 12 membres de l'équipe de service à la clientèle
Utilisation externe	Agent conversationnel accessible à la clientèle de Boréal
Volume typique	Environ 300 interactions avec le chatbot au cours d'une journée ouvrable
Pointe prévue	Environ 6 conversations simultanées
Fonctionnement	Le système sera généralement laissé sous tension en permanence; de courtes fenêtres de maintenance planifiée sont acceptables.

Ces chiffres décrivent le contexte d'utilisation. Le fournisseur logiciel les a déjà traduits en exigences matérielles minimales : il n'est pas nécessaire de recalculer les besoins d'inférence du LLM.

5. Exigences techniques minimales

Processeur	Architecture x86-64 moderne; au moins 8 cœurs physiques.
Mémoire vive	Au moins 64 Go de RAM pour le déploiement initial.
Accélérateur	GPU dédié offrant au moins 24 Go de VRAM utilisable.
Système d'exploitation	Système d'exploitation actuellement pris en charge et compatible avec le matériel choisi. Le fournisseur logiciel prend en charge une édition professionnelle actuelle de Windows 11 64 bits ou une version LTS actuelle d'Ubuntu.
Stockage système	Au moins 2 To sur SSD NVMe pour le système d'exploitation, l'application et les fichiers de travail courants.
Stockage des modèles	Au moins 4 To de capacité utilisable pour les modèles et les versions conservées localement.
Réseau	Au moins 2,5 Gb/s Ethernet.

6. Utilisation du stockage des modèles

Les modèles sont conservés sous forme de fichiers volumineux. Lors du démarrage du service, d'un redémarrage ou d'un changement de modèle, une quantité importante de données doit être lue depuis le stockage afin de charger le modèle. Une fois le modèle chargé, ces fichiers ne sont pas réécrits pour chaque conversation.

Les écritures importantes sur ce volume surviennent surtout lors de l'installation ou du remplacement d'une version du modèle. Boréal s'attend à ce que ces mises à jour soient périodiques plutôt que continues. Après un redémarrage ou une intervention de maintenance, le service doit pouvoir reprendre dans un délai raisonnable.

7. Exigence de continuité

Les fichiers nécessaires au fonctionnement du modèle ne doivent pas dépendre d'un seul dispositif de stockage physique. La défaillance d'un seul dispositif ne doit pas entraîner la perte de ces fichiers ni imposer leur restauration à partir d'une sauvegarde avant que le service puisse être remis en fonction. Boréal n'impose aucune technologie ni organisation précise du stockage pour répondre à cette exigence.

8. Évolution prévue sur cinq ans

Mémoire vive	Pouvoir atteindre au moins 128 Go; une capacité d'expansion supérieure est souhaitable si elle reste raisonnable.
Accélérateur	Ne pas fermer inutilement la possibilité de remplacer le GPU par un accélérateur de classe supérieure. Un besoin futur pourrait viser jusqu'à 48 Go de VRAM.
Stockage	Pouvoir ajouter de la capacité de stockage sans devoir remplacer l'ensemble du système.
Réseau	Conserver une voie d'évolution vers une connexion plus rapide que 2,5 Gb/s si les besoins de l'entreprise augmentent.
Maintenance	Favoriser le remplacement individuel des principaux composants plutôt que le remplacement complet de la machine.

9. Fiabilité, maintenance et contraintes physiques

- Le système soutiendra un service d'entreprise important, mais Boréal ne demande pas une architecture à haute disponibilité composée de plusieurs serveurs.
- De courtes interruptions planifiées pour l'entretien sont acceptables.
- Boréal privilégie, lorsque cela est raisonnable, des composants standards pouvant être diagnostiqués, remplacés et mis à niveau individuellement.
- Les principaux composants devraient être couverts par une garantie appropriée et disposer d'un soutien technique ou d'une documentation technique accessible.
- Le bruit n'est pas une contrainte importante, puisque le système sera installé dans une salle d'équipement.
- Le format physique n'est pas imposé, mais le boîtier et le système de refroidissement doivent convenir aux composants choisis et à leur usage prévu.

10. Infrastructure déjà disponible

Boréal dispose déjà des éléments suivants. Ils ne font pas partie de l'achat demandé :

Local	Salle d'équipement sécurisée et ventilée
Réseau	Connexion Ethernet interne; 2,5 Gb/s disponible pour le nouveau système
Sécurité réseau	Pare-feu et infrastructure de sécurité gérés par l'équipe TI
Alimentation	Onduleur (UPS) adapté au local
Sauvegarde	Stockage réseau destiné aux sauvegardes de l'entreprise
Périphériques	Écran, clavier et souris pour l'administration locale

La conception détaillée du réseau, de la cybersécurité et du système de sauvegarde ne fait pas partie du présent projet.

11. Budget et approvisionnement

Boréal prévoit un budget d'acquisition initial de 8 000 \$ CA avant taxes. La proposition doit être conçue en fonction de ce budget.

Le budget comprend le boîtier, la carte mère, le processeur, le refroidissement du processeur, la mémoire vive, le GPU, le stockage, le bloc d'alimentation, tout refroidissement additionnel nécessaire, une carte réseau additionnelle si elle est requise et une licence de système d'exploitation si le choix proposé en exige une.

Le budget ne comprend pas la main-d'œuvre, le développement du chatbot, l'onduleur, le système de sauvegarde, les périphériques d'administration ni l'infrastructure réseau existante.

Boréal souhaite acheter des composants disponibles sur le marché canadien au moment de l'acquisition et éviter, lorsque cela est possible, les produits annoncés mais non réellement disponibles ou les solutions dont le remplacement dépend d'une source d'approvisionnement très limitée.

12. Question à approfondir : architecture de la mémoire

Boréal souhaite pouvoir augmenter la mémoire vive du système au cours de sa durée de vie. La direction a entendu parler des formats DIMM et CAMM2 et veut savoir si cette distinction devrait influencer le choix d'une plateforme destinée à évoluer pendant plusieurs années. Boréal n'a pas de préférence préalable entre ces approches.

13. Mandat confié

	Mandat Évaluer les options disponibles et recommander à Boréal une configuration informatique cohérente qui répond à ses besoins actuels, respecte ses contraintes et conserve une capacité d'évolution raisonnable.
--	---

Hors du mandat

- Choisir, entraîner ou ajuster le LLM lui-même.
- Calculer à partir de zéro les besoins de mémoire ou de calcul du modèle.
- Développer l'agent conversationnel ou en mesurer les performances en production.
- Concevoir l'architecture complète de cybersécurité, de réseau ou de sauvegarde de l'entreprise.
- Procéder à l'achat, à l'installation ou au déploiement réel du système.